

王熙景

(+1) 408-718-5711 | xthomaswang@gmail.com | xthomaswang.github.io | GitHub | Google Scholar

教育经历

卡内基梅隆大学 (Carnegie Mellon University) 计算机学院
圣塔克拉拉大学 (Santa Clara University) 文理学院
理学学士: 计算机科学 (算法方向), 经济学辅修 | REAL 学者计划

美国宾夕法尼亚州匹兹堡
美国加州圣塔克拉拉
2021.09 – 2025.03

技术能力

编程: Python, C++, Swift, Java, Go, Scala ML / MLSys: PyTorch, TensorFlow, Core ML, coremltools, MLX, TVM/MLC-LLM, Transformers, Faiss
基础设施: 端到端 ML 训练, Core ML package, 端侧 LLM 推理, 模型转换/量化, ML Serving, 多 GPU 训练, RAG, FastAPI, Linux/Shell

工作经历

苹果公司 (Apple) 美国加州库比蒂诺
软件工程实习生 | Python, Core ML, coremltools, MLX, Swift
构建 Cellular ML 模型的 agentic end-to-end training workflow, 串联训练、评估、导出与打包, 生成可部署到 iPhone 测试性能的 Core ML package。
– 在 WWDC26 新发布的 Call Context feature 上使用端侧 LLM 开发新的 iOS feature, 负责 session/prewarm 管理、runtime invocation、跨职能内部设施集成与 iPhone 侧验证/性能。
– 向 Apple ML 生态贡献: coremltools LightGBM 转换器 [PR #2731]; MLX 无 Metal 后端 custom Metal kernel 导出/tracing 支持
开源贡献者 | mlc-ai/mlc-llm & Apache TVM 远程
Embedding serving 与编译/运行时支持 | Python, C++, TVM
– 引入 OpenAI 兼容 /v1/embeddings 服务端点, 支持 Qwen3/BGE embedding serving, pooling/normalization 与跨后端一致性测试。
– 合入 decoder embedding greedy sub-batching, p50 延迟降低 14x (36s→2.5s); 向 Apache TVM 上游 masked sequence prefill 支持
研究工程师 (AI Agent 方向) 美国宾夕法尼亚州匹兹堡
卡内基梅隆大学 | Python, FastAPI, Transformers
构建基于 RAG 的生物医学文献分析平台, 并行检索 PubMed/MedRxiv, 支持快速 (<30s) 和深度 (<3min) 分析模式。
– 在 8x A100 80GB GPU 上微调 Qwen3 0.6B embedding 进行领域适配; 成果发表于 NeurIPS 2025 GenAI4Health
机器学习研究实习生 美国加州圣塔克拉拉
圣塔克拉拉大学认知与计算神经科学实验室 | Python, TensorFlow, Shell
开发 CNN/VGGFace2 后训练与 fMRI HPC 预处理、Pearson 相关分析流程; 第一作者论文被 CogSci 2025 接收并发表于 Communications Biology。
2024.06 – 2024.09

项目经验

Headache Note, 端侧大模型健康助手 | MLC LLM, Swift, SwiftUI, PyTorch [GitHub] 2025
GenAI4Health 私有化部署 | GenAI4Health 在 Apple 生态部署, 提供私密健康建议。 2025
食物识别 iOS App | TensorFlow Lite, Core ML, Python, Swift, Data 2024
训练并部署 Core ML 食物分类模型 (85% 准确率, 100+ 类别), 推理速度提升 4x, 内存占用降低 40%。

发表论文

[NeurIPS '25] GenAI4Health Workshop Poster | [CogSci '25] 第 47 届认知科学学会年会 Poster | [Commun Biol '26] Xijing Wang, Emily Rios, Lang Chen. "E/I imbalance and internal noise cause weak neural representations and face recognition challenges in ASD." Communications Biology. [DOI]