

王熙景

(+1) 408-718-5711 | xthomaswang@gmail.com | xthomaswang.github.io | GitHub | Google Scholar

教育经历

卡内基梅隆大学 (Carnegie Mellon University) 计算机学院

美国宾夕法尼亚州匹兹堡

圣塔克拉拉大学 (Santa Clara University) 文理学院

美国加州圣塔克拉拉

理学学士：计算机科学（算法方向），经济学辅修 | REAL 学者计划

2021.09 - 2025.03

技术能力

编程: Python, C++, Swift, Java, Go, Scala ML / MLSys: PyTorch, TensorFlow, Core ML, coremltools, MLX,

TVM/MLC-LLM, Transformers, Faiss

基础设施: 端到端 ML 训练, Core ML package, 端侧 LLM 推理, 模型转换/量化, ML Serving, 多 GPU 训练, RAG, FastAPI, Linux/Shell

工作经历

苹果公司 (Apple)

美国加州库比蒂诺

软件工程实习生 | Python, Core ML, coremltools, MLX, Swift 2026.05.11 - 2026.08.21

构建 Cellular ML 模型的 agentic end-to-end training workflow, 串联训练、评估、导出与打包, 生成可部署到 iPhone 测试性能的

Core ML package.

- 参与 WWDC26 Call Context 端侧 LLM 推理工作, 围绕模型打包、运行时验证与 iPhone 推理性能建立自动化 workflow.

- 向 Apple ML 生态贡献: coremltools LightGBM 转换器 [PR #2731]; MLX 无 Metal 后端 custom Metal kernel 导出/tracing 支持

开源贡献者 | - mlc-ai/mlc-llm & Apache TVM 2026.02 - 至今

Embedding serving 与编译/运行时支持 | Python, C++, TVM

引入 OpenAI 兼容 /v1/embeddings 服务端点, 支持 Qwen3/BGE embedding serving、pooling/normalization 与跨后端一致性测试.

- 合入 decoder embedding greedy sub-batching, p50 延迟降低 14x (36s→2.5s); 向 Apache TVM 上游 masked sequence prefill 支

研究工程师 (AI Agent 方向) 美国宾夕法尼亚州匹兹堡

卡内基梅隆大学 | Python, FastAPI, Transformers 2025.07 - 2025.12

构建基于 RAG 的生物医学文献分析平台; 并行检索 PubMed/MedRxiv, 支持快速 (<30s) 和深度 (<3min) 分析模式.

- 在 8x A100 80GB GPU 上微调 Qwen3 0.6B embedding 进行领域适配; 成果发表于 NeurIPS 2025 GenAI4Health

机器学习研究实习生 美国加州圣塔克拉拉

圣塔克拉拉大学认知与计算神经科学实验室 | Python, TensorFlow, Shell 2024.06 - 2024.09

开发 CNN/VGGFace2 后训练与 fMRI HPC 预处理、Pearson 相关分析流程; 第一作者论文被 CogSci 2025 接收并发表于

Communications Biology.

项目经验

Headache Note - 端侧大模型健康助手 | MLC-LLM, Swift, SwiftUI, PyTorch [GitHub] 2025

GenAI4Health 车内语音交互系统 | Phoenix AGO, 在 Phoenix AGO 端侧推理引擎中集成 SwiftData 提供私密健康建议. 2025

食物识别 iOS 应用 | GenAI4Health, 在 Phoenix AGO 端侧推理引擎中集成 SwiftData 提供私密健康建议. 已被研究实验室采用. 2024

训练并部署 Core ML 食物分类模型 (85% 准确率, 100+ 类别), 推理速度提升 4x, 内存占用降低 40%.

发表论文

[NeurIPS '25] GenAI4Health Workshop Poster | [CogSci '25] 第 47 届认知科学学会年会 Poster | [Commun Biol '26] Xijing Wang,

Emily Rios, Lang Chen. "E/I imbalance and internal noise cause weak neural representations and face recognition challenges in ASD."

Communications Biology. [DOI]